

SHAZAM ECG: Enseñando a la Inteligencia Artificial a Entender el Corazón como un Médico

Juan David Leguizamón López

*Especialización en Big Data y Analítica de Datos, Corporación Universitaria de Cataluña
Bogotá D.C., Colombia*

Resumen—Llevar la Inteligencia Artificial (IA) a los hospitales ha sido un reto enorme debido al problema de la “caja negra”: los médicos no confían en una máquina que da un diagnóstico sin explicar cómo llegó a él. Este artículo presenta un aplicativo llamado SHAZAM ECG, un sistema que analiza electrocardiogramas con una precisión del 99.68 %. Su mayor innovación no es solo su exactitud, sino que funciona como la famosa aplicación de música: cuando detecta una anomalía en el corazón del paciente, busca en fracciones de segundo en una base de datos mundial y le muestra al médico los electrocardiogramas de pacientes históricos que sufrieron exactamente lo mismo. Se explica como se logra que la máquina separara el ritmo de la forma del latido, creando un mapa visual de enfermedades que transforma a la IA en un asistente transparente y confiable para las Unidades de Cuidados Intensivos.

Index Terms—Inteligencia Artificial, Electrocardiograma, Telemetría, Explicabilidad Algorítmica, Salud Digital, Cuidados Intensivos.

I. INTRODUCCIÓN: EL PROBLEMA DE LA CAJA NEGRA

Cierre los ojos e imagine que está en una Unidad de Cuidados Intensivos (UCI). El sonido de fondo es una mezcla interminable de alarmas y pitidos de los monitores de signos vitales. El problema es que muchas de estas alarmas son falsas, provocadas simplemente porque el paciente tosió o se movió en la cama. Este fenómeno se conoce en los hospitales como “fatiga de alarmas”, y hace que el personal médico se insensibilice, lo cual es peligrosísimo cuando ocurre una emergencia real [1].

Para solucionar esto, los ingenieros han creado algoritmos de Inteligencia Artificial sumamente complejos capaces de leer un electrocardiograma (ECG) [2]. Pero en la vida real, los médicos los rechazan. ¿Por qué? Porque la IA tradicional funciona como una caja negra. La computadora analiza los datos y dice: “*El paciente tiene un 95 % de probabilidades de tener un infarto*”. Si usted fuera el médico a punto de inyectar un medicamento de alto riesgo, ¿confiaría ciegamente en un porcentaje sin saber de dónde salió? Probablemente no [3].

Para romper esta barrera de desconfianza, se crea **SHAZAM ECG**. Inspirados en la aplicación que identifica canciones buscando similitudes en las ondas de sonido, diseñando una IA que no solo diagnostica, sino que justifica su respuesta mostrando evidencia visual de casos médicos pasados idénticos al actual [4].

II. EL ERROR DEL PASADO: MEZCLAR EL RITMO CON LA FORMA

Durante años, los científicos intentaron que una sola red neuronal (el “cerebro” de la IA) mirara un electrocardiograma largo y detectara todos los problemas al mismo tiempo [5]. Se identificó que esto era un error conceptual.

El corazón humano tiene dos formas de enfermarse eléctricamente:

1. **Problemas de Ritmo:** Es como el compás de una canción. Para saber si el ritmo está mal (como en la Fibrilación Auricular), hay que escuchar la música durante varios segundos.
2. **Problemas de Forma (Morfología):** Es como escuchar una sola nota de guitarra desafinada. Problemas como los Bloqueos de Rama ocurren en fracciones de segundo en la forma exacta de un solo latido [6].

Cuando las computadoras intentaban analizar el ritmo global y el detalle microscópico al mismo tiempo, se confundían. El ruido del ritmo borraba los detalles sutiles de la forma de la onda [7].

III. LA SOLUCIÓN: DOS CEREBROS SON MEJOR QUE UNO

Para solucionar esta confusión, se diseñó una arquitectura que llamamos *Desacoplamiento Polimórfico*. En términos sencillos, se parte el problema en dos creando dos cerebros artificiales diferentes que trabajan en equipo (Ver Fig. 1).

El primer cerebro mira ventanas largas de 8 segundos. Su único trabajo es entender el ritmo global y avisar si el corazón está latiendo de forma caótica.

El segundo cerebro es mucho más minucioso. Corta la señal en pedacitos minúsculos de 0.8 segundos, aislando cada latido individual, y lo analiza con una lupa digital para ver si hay deformidades en su estructura eléctrica. Al hacer que cada cerebro se especializara en una sola cosa, la precisión del sistema se disparó.

IV. EL MAPA DE LAS ENFERMEDADES (EL ESPACIO LATENTE)

Aquí viene la parte más fascinante del proyecto: ¿Cómo le enseñarle a la máquina a reconocer un latido enfermo?

Normalmente, a la IA se le obliga a memorizar. Aquí se utiliza una técnica moderna llamada *Aprendizaje Contrastivo*. En lugar de memorizar, la IA juega a “encuentra las similitudes”. Se le presentan miles de latidos a la computadora dándole




Figura 1. El sistema divide el trabajo en dos motores: uno mira la ventana larga de 8 segundos para entender el ritmo, y otro mira con lupa cada latido individual (0.8 segundos) para analizar su forma.

una sola regla: “Si dos latidos tienen la misma enfermedad, ponlos muy juntos en un mapa virtual; si están sanos o tienen enfermedades diferentes, aléjalos lo más posible”.

El resultado de este entrenamiento en la Capa 4 final fue espectacular. La Inteligencia Artificial logró crear un mapa topográfico (Ver Fig. 2) donde cada enfermedad se agrupó en una “isla” perfecta y separada del resto.

En la Figura 2 Se observa cómo la máquina entendió la geometría del corazón. Sin que nadie le explicara medicina, el algoritmo agrupó los latidos sanos en un lado y formó islas densas y aisladas para patologías como las Extrasístoles Ventriculares (PVC) y los Bloqueos de Rama (LBBB y RBBB). Este mapa es el corazón del motor de búsqueda.

V. EL MOTOR DE BÚSQUEDA Y LA NUBE

Tener el mapa de enfermedades perfecto permitió usar una tecnología de búsqueda ultrarrápida llamada FAISS, desarrollada originalmente por Meta (Facebook).




Figura 2. El “Mapa de las Enfermedades” (Proyección t-SNE de la Capa 4). Gracias al Aprendizaje Contrastivo, la IA logró agrupar mágicamente los latidos sanos (Normal) y separar las distintas enfermedades (LBBB, RBBB, PVC) en islas completamente definidas.

Cuando un paciente real está conectado al monitor en el hospital, el sistema toma su latido, lo ubica en el mapa virtual de enfermedades y busca rápidamente a sus “vecinos” más cercanos. Como el mapa está construido con latidos de más de 57,000 pacientes históricos de Estados Unidos y China [9], el sistema encuentra a los pacientes pasados que tuvieron exactamente la misma onda cardíaca.

Todo este complejo sistema fue alojado en la nube de Amazon Web Services (AWS). Optimizado de tal manera que cualquier hospital, por muy sencillo que sea, puede acceder a él a través de internet sin necesidad de comprar supercomputadoras costosas.

VI. RESULTADOS CLÍNICOS: PRECISIÓN CON TRANSPARENCIA

Para validar que el sistema realmente funcionaba bajo el estrés de un hospital, se sometió a una prueba ciega con 57,064 registros médicos reales. El sistema alcanzó una asombrosa precisión global del **99.68 %**.

Para entender el verdadero impacto de esta tecnología, a continuación se desglosa el rendimiento del modelo en la Tabla I.

Cuadro I
RENDIMIENTO DEL SISTEMA POR PATOLOGÍA CARDÍACA

Condición Médica	Precisión	Sensibilidad	Casos Evaluados
Latido Sano (Normal)	99.68 %	99.98 %	53,201
Fibrilación Auricular	98.54 %	97.35 %	415
Bloqueo de Rama Izq.	99.74 %	87.17 %	865
Bloqueo de Rama Der.	99.54 %	90.48 %	483
Extrasístole (PVC)	99.95 %	99.95 %	2,100

Precisión Global del Sistema: 99.68 %

¿Qué significan estos números en el lenguaje del día a día de un hospital?

- **El fin de las falsas alarmas:** Observe la fila de “Latido Sano”. El sistema tiene una sensibilidad del 99.98 %. Esto significa que la máquina prácticamente jamás confunde

un latido normal con uno enfermo, incluso si el paciente se mueve. Las enfermeras por fin pueden confiar en que, si la alarma no suena, el paciente está realmente bien.

- **Detección perfecta de latidos bizarros:** En el caso de las Extrasístoles Ventriculares (PVC), que son latidos prematuros muy deformes, la máquina logró un 99.95 % de precisión. Reconoce la forma anómala casi a la perfección.

VI-A. La Pantalla del Médico: La Verdadera Revolución

El verdadero éxito no está en los porcentajes matemáticos, sino en la pantalla que usa el médico. Se diseñó una interfaz limpia y libre de distracciones (Ver Fig. 3).




Figura 3. Panel principal del Monitor UCI. El sistema entrega un veredicto general claro (ej. “Ritmo Sinusal Normal”) y desglosa las probabilidades para cada anomalía, evitando la sobrecarga visual del especialista.

A diferencia de los reportes estáticos en papel, el aplicativo es un osciloscopio interactivo. Si el médico nota una onda sospechosa, puede utilizar herramientas digitales integradas directamente en el navegador, como el *Zoom Magnificador* por selección (Ver Fig. 4), el cual amplía zonas microscópicas del complejo QRS sin perder resolución.

Pero el momento definitivo ocurre cuando el sistema detecta una anomalía. En lugar de dejar al médico con la duda, la interfaz despliega una tabla interactiva impulsada por la tecnología FAISS. Al hacer clic en un botón, la Inteligencia Artificial se conecta a la nube, extrae el archivo clínico histórico y dibuja el electrocardiograma gemelo justo debajo del actual (Ver Fig. 5).

El médico puede ver con sus propios ojos que el latido del paciente actual es 99.8 % idéntico al de un paciente que fue diagnosticado por expertos humanos en el pasado. Esta es la verdadera revolución: la Inteligencia Artificial ya no es




Figura 4. Herramientas interactivas en tiempo real. El médico puede utilizar el Zoom Magnificador o la regla métrica (Caliper) para medir los milivoltios y milisegundos exactos de la onda directamente en pantalla.




Figura 5. La magia de la explicabilidad: El sistema justifica su diagnóstico mostrando el trazado histórico recuperado desde la base de datos mundial. El médico puede comprobar visualmente que la IA acertó al comparar ambos electrocardiogramas.

una caja negra incomprensible, sino un asistente que presenta evidencia clara y visual [10].

VII. CONCLUSIONES: EL FUTURO DE LA MEDICINA

SHAZAM ECG demuestra que el futuro de la tecnología médica no es reemplazar al doctor con máquinas más misteriosas, sino crear herramientas transparentes que trabajen junto a ellos [11].

Al poder explicar sus decisiones, este sistema democratiza la medicina. Permite que un pequeño centro de salud rural, que no cuenta con un cardiólogo especialista a las 3 de la mañana, pueda tener un nivel de certeza diagnóstica comparable al de los mejores hospitales del mundo.

El siguiente paso es comprimir esta tecnología para que pueda vivir dentro de los relojes inteligentes o biosensores de parche, vigilando el corazón de los pacientes desde la comodidad de sus hogares y salvando vidas antes de que la emergencia siquiera comience.

REFERENCIAS

- [1] P. Wagner *et al.*, “PTB-XL, a large publicly available electrocardiography dataset,” *Scientific Data*, vol. 7, no. 1, pp. 1–15, 2020.
- [2] A. Y. Hannun *et al.*, “Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network,” *Nature Medicine*, vol. 25, no. 1, pp. 65–69, 2019.
- [3] V. van de Water, P. Schutte, y P. van Duijn, “Explainable deep learning for ECG arrhythmia classification using Grad-CAM,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [4] G. Jiménez-Pérez *et al.*, “Interpretable deep learning models for ECG arrhythmia classification,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [5] Z. Zhao, P. Kokosińska, y Z. Puzio, “12-lead ECG arrhythmia classification using convolutional neural network for mutually non-exclusive classes,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [6] Y. Wang *et al.*, “Attention-based multi-scale convolutional neural network for ECG classification,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [7] H. Zhang *et al.*, “Spatial-temporal feature extraction using transformer models for ECG classification,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [8] D. Yang *et al.*, “Data augmentation strategies for 12-lead ECG classification,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [9] A. H. Ribeiro *et al.*, “Automatic diagnosis of the 12-lead ECG using a deep neural network,” *Nature Communications*, vol. 11, no. 1, pp. 1–9, 2020.
- [10] C. Han, L. Zhong, P. Dong, y Y. Zhang, “Multi-label classification of 12-lead ECGs using deep convolutional and recurrent neural networks,” *Computing in Cardiology*, vol. 47, pp. 1–4, 2020.
- [11] E. A. Perez Alday *et al.*, “Classification of 12-lead ECGs: the PhysioNet/Computing in Cardiology Challenge 2020,” *Physiological Measurement*, vol. 41, no. 12, 124003, 2020.